



UNIVERSIDAD DE EXTREMADURA

CENTRO UNIVERSITARIO DE MÉRIDA

GRADO EN INGENIERÍA INFORMÁTICA EN
TECNOLOGÍAS DE LA INFORMACIÓN

TRABAJO FIN DE GRADO

OPTIMIZACIÓN DE PROBLEMA DE RIEGO
EFICIENTE EN HIGUERA MEDIANTE
INTELIGENCIA ARTIFICIAL

PABLO SETRAKIAN BEARZOTTI

Mérida, Junio de 2024



UNIVERSIDAD DE EXTREMADURA

CENTRO UNIVERSITARIO DE MÉRIDA

GRADO EN INGENIERÍA INFORMÁTICA EN
TECNOLOGÍAS DE LA INFORMACIÓN

TRABAJO FIN DE GRADO

OPTIMIZACIÓN DE PROBLEMA DE RIEGO
EFICIENTE EN HIGUERA MEDIANTE
INTELIGENCIA ARTIFICIAL

Autor: Pablo Setrakian Bearzotti
Fdo:

Director: Francisco Chávez de la O
Fdo:

Agradecimientos

En primer lugar, quiero agradecer a mis padres por animarme a estudiar ingeniería informática y por su apoyo incondicional durante toda mi formación académica.

A mi profesor Francisco Chávez de la O por sus clases, las cuales me hicieron empezar a interesarme por la inteligencia artificial y por su propuesta para participar en este proyecto.

Resumen

La seguridad alimentaria representa uno de los desafíos más críticos de la actualidad, especialmente en el contexto de la detección temprana de contaminantes que pueden representar riesgos significativos para la salud humana. Las micotoxinas, sustancias tóxicas producidas por hongos como el *Aspergillus flavus*, constituyen una amenaza considerable en la cadena alimentaria, siendo clasificadas por la Agencia Internacional para la Investigación del Cáncer como sustancias carcinógenas del grupo 1.

La detección tradicional de micotoxinas en productos agrícolas requiere métodos invasivos que implican la destrucción de las muestras, lo que resulta en pérdidas económicas significativas y limitaciones en el control de calidad durante el proceso productivo. En este contexto, el desarrollo de técnicas no invasivas para la detección temprana de contaminación por aflatoxinas se presenta como una necesidad imperante para la industria agroalimentaria.

Este Trabajo Fin de Grado se centra en el desarrollo de un sistema de inteligencia artificial capaz de detectar la contaminación por micotoxinas en higos frescos mediante el análisis de imágenes hiperespectrales y técnicas de inteligencia artificial. El proyecto aborda específicamente la clasificación de estados de enfermedad en frutos de higuera, utilizando un algoritmo genético junto a una red neuronal para identificar la presencia de *Aspergillus flavus* en diferentes concentraciones de contaminación.

La metodología propuesta se estructura en múltiples fases, comenzando con la localización y segmentación de higos individuales mediante detección RGB, seguida de la selección de bandas espectrales más informativas utilizando un algoritmo genético, y culminando con el procesamiento de parches espectrales completos mediante transformadas wavelet. Esta aproximación multimodal permite aprovechar tanto la información espectral específica como las características espaciales de las imágenes hiperespectrales.

Los resultados preliminares demuestran la viabilidad del enfoque propuesto para la detección no invasiva de contaminación por micotoxinas, estableciendo un marco de trabajo que contribuirá significativamente a mejorar los estándares de seguridad alimentaria en la producción de higos, especialmente relevante para regiones productoras como Extremadura, que representa el 55.5 % de la producción nacional española.

Palabras clave - inteligencia artificial, imágenes hiperespectrales, aprendizaje automático, visión por computador, algoritmo genético

Abstract

Artificial intelligence is no longer just a futuristic promise, but a reality that is redefining the way we interact with the world and conduct business. From healthcare to the manufacturing industry, AI has demonstrated its ability to radically transform diverse fields, unleashing a series of changes that are revolutionising today. Artificial intelligence will enable the automation of a wide range of complex processes that currently still require human intervention.

Artificial intelligence which, through methods, techniques and algorithms, provides computers the ability of identifying patterns in massive data and make predictions (predictive analytics). This learning allows computers to carry out specific tasks autonomously, i.e. without the need to be programmed.

The constant innovation and evolution of the emerging technologies, paired with the use by the vast majority of the world's population, has led to organisations exploiting the power of the automatic learning methods to help them extract better quality information, increase productivity, reduce the costs and get more value from their data.

In an ever-evolving world where technology is redefining the way we live, agriculture is no exception. Artificial intelligence is emerging as a key tool to help farmers adapt to the effects of climate change and lessen its impact. By capitalising on artificial intelligence, farmers can make informed, data-driven decisions and anticipate the climate shifts.

This research deals with sustainable production systems in the cultivation of fig trees and the study of water needs in order to design irrigation strategies using a set of automatic learning techniques belonging to the world of artificial intelligence.

Lastly, once the results generated by the entire system created have been obtained, these will be analysed and the solutions to the problems presented will be identified. These will allow us to observe the degree of efficiency of the experiments developed and to know if they meet the proposed targets.

Keywords - Artificial Intelligence, Agriculture, Climate change

Índice general

Agradecimientos	I
Índice de figuras	VII
Índice de tablas	IX
1. Introducción	1
1.1. Introducción	1
1.2. Motivación	2
1.3. Objetivo general	2
1.4. Objetivos específicos	3
1.5. Planificación	4
1.6. Organización del documento	4
2. Estado del Arte	6
2.1. Introducción	6
2.2. HSI en Agricultura de Precisión	6
2.3. Imágenes RGB en Agricultura de Precisión	8
2.4. ML en Imagenología Agrícola	9
3. Desarrollo	12
3.1. Introducción	12
3.2. Entorno de Desarrollo	12
3.2.1. Gestión de Entornos y Dependencias	12
3.2.2. Entorno de Desarrollo Integrado	14
3.2.3. Infraestructura Computacional	14
3.2.4. Adquisición de Imágenes Hiperespectrales	14
3.3. Localización y Segmentación de Figuras	16
3.3.1. Objetivo de la Fase	16
3.3.2. Herramientas y Tecnologías Empleadas	16
3.3.3. Flujo de Procesamiento	18

3.3.4.	Resultados	21
3.3.5.	Desafíos y Observaciones Técnicas	23
3.4.	Selección de Bandas con Algoritmo Genético	23
3.4.1.	[Sección reservada para Fase 2: Selección de Bandas con Algoritmo Genético]	23
4.	Resultados	24
5.	Conclusiones y Trabajo Futuro	25
5.1.	Conclusiones	25
5.1.1.	Logros Principales	25
6.	Agradecimientos	26
	Referencias	27

Índice de figuras

3.1. Ejemplo de detección y segmentación de higos utilizando <i>Grounding DINO</i> y <i>SAM-2</i> . La imagen muestra las cajas delimitadoras generadas por <i>Grounding DINO</i> y las máscaras de segmentación producidas por <i>SAM-2</i>	20
3.2. Ejemplo de anotación en formato COCO para la clase 0. . . .	22

Índice de tablas

Capítulo 1

Introducción

1.1. Introducción

Las enfermedades y plagas en cultivos representan un desafío económico significativo para los sectores agrícola y alimentario a nivel mundial. Entre las amenazas más graves se encuentran las micotoxinas, sustancias producidas naturalmente por ciertos tipos de hongos bajo condiciones particulares de humedad y temperatura. La presencia de micotoxinas en alimentos constituye un problema serio tanto para la salud humana como animal. La Agencia Internacional para la Investigación del Cáncer (IARC) ha clasificado un grupo de aflatoxinas como sustancias carcinogénicas del grupo 1, siendo la vía común de exposición a micotoxinas la ingesta de alimentos contaminados.

El hongo *Aspergillus flavus*, que prolifera a temperaturas entre 12°C y 27°C con 85 % de humedad, se multiplica en diversos alimentos incluyendo maíz, cacahuetes, arroz, frutos secos e higos. Aunque su presencia es típica de climas tropicales, también prolifera bajo ciertas condiciones de riego. El ciclo de crecimiento de la aflatoxina es de entre 3 y 5 días. Incluso si los higos van a ser secados, la introducción de higos infectados con aflatoxinas en el proceso puede provocar la contaminación de otros frutos. Por tanto, la detección de aflatoxinas en el producto fresco se considera crucial tanto para el consumo directo como para su procesamiento posterior.

El cultivo de la higuera (*Ficus carica* L.) tiene sus orígenes en la región de Caria en Asia, habiéndose extendido a otras áreas como la región mediterránea, África y América. España es actualmente el sexto mayor productor mundial, representando el 3.5 % de la producción global. La región de Extremadura, con 12,771 hectáreas cultivadas, representa el mayor productor

en España, alcanzando el 55.5 % de la producción nacional. El aumento en la productividad está vinculado a la adopción de técnicas innovadoras como fertilización, poda, tratamiento del suelo e irrigación. Sin embargo, los cambios en la humedad facilitan la propagación de la micotoxina *Aspergillus flavus*, requiriendo investigación adicional para analizar y prevenir que higos infectados entren en la cadena alimentaria humana.

1.2. Motivación

La detección tradicional de aflatoxinas se realiza mediante métodos invasivos que requieren la destrucción de la muestra, o mediante inspección visual en etapas avanzadas de contaminación. Estos métodos presentan limitaciones significativas: son lentos, costosos, y no permiten el análisis en tiempo real durante el proceso productivo. Además, los higos frescos son perecederos, tienen una vida útil limitada y son más sensibles al crecimiento microbiano que los higos secos, alterando la calidad del producto y representando un riesgo serio para la salud humana.

El uso de imágenes hiperespectrales (HSI) combinado con técnicas de inteligencia artificial, particularmente el deep learning, ofrece una alternativa prometedora. La tecnología HSI mide la interacción de un amplio espectro de luz con un objeto determinado, adquiriendo cientos de bandas espectrales contiguas para cada píxel en una imagen. Esta capacidad proporciona información detallada sobre el objeto y revela diferencias sutiles en textura y composición química que no son detectables mediante métodos convencionales.

La necesidad de desarrollar métodos no invasivos y precisos para la detección temprana de contaminación por aflatoxinas en higos frescos es crítica para garantizar la seguridad alimentaria, reducir pérdidas económicas en la cadena de producción, y proteger la salud pública.

1.3. Objetivo general

Desarrollar un sistema de inteligencia artificial basado en el análisis de imágenes hiperespectrales para la detección temprana de contaminación por micotoxinas en higos frescos, utilizando técnicas de deep learning y algoritmos genéticos para optimizar la selección de características espectrales relevantes.

1.4. Objetivos específicos

- Implementar un sistema de detección y segmentación automática de higos individuales en imágenes RGB mediante técnicas de visión por computador, generando máscaras y anotaciones para su posterior extracción de datos hiperespectrales.
- Desarrollar e implementar un algoritmo genético para la selección óptima de las tres bandas espectrales más informativas del cubo hiperespectral, reduciendo la dimensionalidad de los datos mientras se mantiene la capacidad discriminativa.
- Diseñar y entrenar modelos de redes neuronales profundas capaces de clasificar el estado de contaminación de los higos basándose en las bandas espectrales seleccionadas, evaluando diferentes arquitecturas y configuraciones.

1.5. Planificación

El desarrollo del proyecto se estructura en las siguientes fases principales, diseñadas para abordar progresivamente los desafíos técnicos y científicos:

1. **Fase de preparación y adquisición de datos:** Recolección del dataset de imágenes hiperespectrales incluyendo muestras contaminadas con diferentes niveles de micotoxinas y muestras de control no contaminadas, capturadas durante un período de dos semanas para garantizar diversidad y robustez.
2. **Fase 0 - Detección y segmentación:** Desarrollo del sistema de detección automática de higos individuales mediante modelos de object detection y segmentación aplicados a versiones RGB de las imágenes hiperespectrales, generando máscaras y anotaciones en formato COCO.
3. **Fase 1 - Selección de bandas con algoritmo genético:** Implementación del algoritmo genético para identificar las tres bandas espectrales más informativas del cubo hiperespectral, construyendo imágenes reducidas para el entrenamiento de redes neuronales.
4. **Fase de validación y documentación:** Evaluación exhaustiva de los modelos desarrollados, análisis comparativo de resultados, y preparación de la documentación técnica y científica del proyecto.

1.6. Organización del documento

El presente documento se estructura en los siguientes capítulos para presentar de manera sistemática el desarrollo y resultados del proyecto:

- **Capítulo 2. Marco teórico y estado del arte:** Presenta los fundamentos teóricos de las imágenes hiperespectrales, técnicas de deep learning aplicadas a la agricultura de precisión, y una revisión exhaustiva de trabajos relacionados con la detección de aflatoxinas mediante métodos no invasivos.
- **Capítulo 3. Desarrollo:** Detalla la metodología implementada en cada fase del proyecto, incluyendo la arquitectura del sistema de detección y segmentación, el diseño del algoritmo genético, y la implementación de los modelos de redes neuronales profundas.

- **Capítulo 4. Resultados:** Presenta los resultados experimentales obtenidos en cada fase, incluyendo métricas de rendimiento, análisis comparativo entre diferentes aproximaciones, y evaluación del impacto computacional y energético de los modelos.
- **Capítulo 5. Conclusiones y trabajo futuro:** Resume las contribuciones principales del proyecto, discute las limitaciones encontradas, y propone líneas de investigación futuras para mejorar y extender el sistema desarrollado.

Capítulo 2

Estado del Arte

2.1. Introducción

La agricultura de precisión ha experimentado una transformación significativa en las últimas décadas, impulsada por el desarrollo de tecnologías emergentes que permiten el monitoreo y análisis automatizado de cultivos [1, 2]. En este contexto, las tecnologías de imagenología avanzada, particularmente las imágenes hiperespectrales (HSI) y RGB, han emergido como herramientas clave para la detección temprana de contaminantes y patógenos en productos agrícolas. La integración de estas tecnologías con algoritmos de machine learning ha abierto nuevas posibilidades para el desarrollo de sistemas de detección no invasivos, precisos y eficientes [2, 3, 4].

Este capítulo presenta una revisión sistemática del estado del arte en tecnologías de detección de contaminantes en productos agrícolas, centrándose en la aplicación de imágenes hiperespectrales y RGB en combinación con técnicas de aprendizaje automático. El análisis ofrece el marco teórico necesario para comprender las contribuciones de este proyecto y su relevancia dentro del panorama científico actual.

2.2. HSI en Agricultura de Precisión

La imagenología hiperespectral constituye un avance notable en el análisis remoto, ya que permite capturar información extremadamente detallada a través de cientos de bandas espectrales contiguas por cada píxel. Este enfoque mide cómo un amplio rango del espectro electromagnético interactúa con un objeto, proporcionando información sobre su composición química y revelando variaciones sutiles que los métodos convencionales no pueden detectar. La capacidad de HSI para capturar características a través de múltiples bandas

permite crear firmas únicas que representan cómo diferentes materiales responden a cada longitud de onda. Según la literatura científica, cuanto mayor es el número de bandas, más detalladas son las características que pueden ser identificadas, aunque no todas las bandas incluyen información relevante para mejorar la precisión de detección [5].

Los sistemas HSI típicamente operan en diferentes rangos espectrales, incluyendo el visible (VIS: 400-700 nm), infrarrojo cercano (NIR: 700-1000 nm), infrarrojo de onda corta (SWIR: 1000-2500 nm), y otros rangos especializados. Esta versatilidad espectral permite identificar características específicas de materiales y cambios químicos imperceptibles para el ojo humano o sistemas de imagen convencionales.

La aplicación de HSI en la detección de contaminantes agrícolas ha mostrado resultados prometedores en numerosos estudios. Estas investigaciones han abordado la identificación de infecciones fúngicas, micotoxinas y otros patógenos que comprometen la calidad y la seguridad de los productos alimentarios. En el contexto específico de detección de aflatoxinas, varios estudios han explorado el potencial de HSI para la identificación temprana de contaminación. La investigación ha demostrado que las aflatoxinas, particularmente la Aflatoxina B1 producida por *Aspergillus flavus*, pueden ser detectadas utilizando análisis espectral no invasivo. Estudios recientes han aplicado HSI con cámaras VNIR (400-1000 nm) y SWIR (1000-2500 nm) en diversos cultivos, logrando resultados prometedores en la identificación de muestras contaminadas frente a controles sanos.

La distribución superficial de las aflatoxinas representa una ventaja particular para el análisis mediante HSI, ya que permite detectar cambios químicos y estructurales en las capas exteriores de los productos agrícolas. Esta característica facilita la implementación de sistemas de detección que no requieren la destrucción de las muestras, manteniendo la integridad del producto para su comercialización.

A pesar de las ventajas evidentes de HSI, existen desafíos significativos asociados con su implementación práctica. El principal desafío radica en la alta dimensionalidad de los datos hiperespectrales, que puede representar un obstáculo considerable para los algoritmos de clasificación tradicionales [5]. Los cubos hiperespectrales generan volúmenes masivos de datos complejos que requieren técnicas especializadas de procesamiento y análisis. La gestión de la dimensionalidad espectral requiere estrategias de selección de características y reducción dimensional para identificar las bandas espec-

trales más informativas. La eliminación de bandas espectrales redundantes no solo facilita el análisis computacional, sino que también puede mejorar la precisión de clasificación al reducir el ruido y la información irrelevante. Adicionalmente, las condiciones de adquisición de imágenes hiperespectrales requieren un control cuidadoso de factores ambientales como la iluminación, temperatura y humedad, que pueden afectar la calidad y consistencia de los datos espectrales. La calibración y normalización de los datos espectrales son procedimientos críticos para garantizar la reproducibilidad y confiabilidad de los resultados.

2.3. Imágenes RGB en Agricultura de Precisión

En el ámbito agrícola, las imágenes RGB siguen siendo la tecnología más extendida [6]. Aunque limitadas en comparación con HSI, destacan por su bajo costo, simplicidad de uso y rapidez en el procesamiento, cualidades que han facilitado su implementación a gran escala. Los sistemas RGB capturan únicamente tres bandas espectrales correspondientes a los colores primarios, generando representaciones visuales similares a la percepción humana. A pesar de su simplicidad, esta información resulta suficiente para detectar variaciones morfológicas y de color asociadas con infecciones fúngicas u otros contaminantes.

La literatura científica documenta numerosas aplicaciones exitosas de imágenes RGB en la detección de contaminantes agrícolas. Estos sistemas han demostrado eficacia particular en la identificación de cambios visuales asociados con infecciones fúngicas, decoloración y alteraciones morfológicas que preceden o acompañan la contaminación por micotoxinas. En el contexto de detección de aflatoxinas, algunos estudios han explorado el uso de imágenes RGB para identificar cambios visuales en productos contaminados. Aunque la información espectral limitada de RGB puede restringir la detección de cambios químicos sutiles, la tecnología ha mostrado utilidad en la identificación de síntomas visuales avanzados de contaminación fúngica.

Las aplicaciones RGB se han extendido también a sistemas de clasificación automatizada para el control de calidad en líneas de producción, donde la velocidad de procesamiento y la simplicidad del sistema son factores críticos. Estos sistemas pueden proporcionar una primera línea de defensa en la detección de productos visiblemente afectados.

Las principales limitaciones de los sistemas RGB radican en su capacidad limitada para detectar cambios químicos sutiles que no se manifiestan visualmente. La contaminación por micotoxinas puede ocurrir sin síntomas visuales evidentes en las etapas tempranas, limitando la efectividad de los sistemas RGB para la detección precoz. Adicionalmente, los sistemas RGB son susceptibles a variaciones en las condiciones de iluminación y pueden requerir normalización cuidadosa para mantener la consistencia en diferentes entornos. La dependencia de características visuales también puede resultar en falsos positivos cuando se presentan variaciones naturales en color o textura que no están relacionadas con contaminación.

2.4. ML en Imagenología Agrícola

La aplicación de Deep Learning (DL) en el procesamiento de imágenes hiperespectrales ha revolucionado las capacidades de análisis y clasificación en agricultura de precisión [7]. Como subconjunto del machine learning, el deep learning utiliza redes neuronales profundas que consisten en múltiples capas interconectadas de neuronas artificiales capaces de aprender representaciones de alto nivel a partir de datos de entrada.

La implementación de DL para el procesamiento y análisis de imágenes hiperespectrales fue inicialmente descrita en investigaciones pioneras que propusieron enfoques de clasificación utilizando información espacialmente dominante [8]. Desde entonces, un gran número de estudios han reflejado el interés creciente de la comunidad científica en esta área de investigación.

Las redes neuronales convolucionales tridimensionales han emergido como una arquitectura particularmente efectiva para el procesamiento de cubos hiperespectrales [9]. Estas redes pueden capturar simultáneamente características espaciales y espectrales, aprovechando la naturaleza tridimensional inherente de los datos hiperespectrales. Las CNN 3D operan mediante la aplicación de filtros convolucionales tridimensionales que se desplazan a través de las dimensiones espaciales (x , y) y espectral (z) del cubo hiperespectral. Esta capacidad permite la extracción de características que consideran tanto la variabilidad espacial local como las relaciones espectrales entre bandas adyacentes.

Una alternativa prometedora al uso directo de redes 3D consiste en la aplicación de transformadas matemáticas al espectro hiperespectral antes del procesamiento con redes neuronales [4]. Las transformadas wavelet han

mostrado particular eficacia en este contexto, permitiendo la descomposición del espectro en componentes de frecuencia que pueden ser procesados mediante arquitecturas de red más simples. El enfoque basado en transformadas wavelet ofrece ventajas computacionales significativas, ya que permite la conversión de firmas espectrales unidimensionales en representaciones bidimensionales que pueden ser procesadas eficientemente mediante CNN 2D convencionales. Esta metodología puede mantener la información espectral crítica mientras reduce la complejidad computacional del procesamiento.

Las redes neuronales convolucionales bidimensionales (CNN 2D) representan el estándar establecido para el procesamiento de imágenes RGB en aplicaciones agrícolas [6]. Estas arquitecturas han demostrado eficacia excepcional en tareas de clasificación, detección de objetos y segmentación semántica aplicadas a productos agrícolas. Las CNN 2D operan mediante la aplicación de filtros convolucionales que capturan características espaciales locales en las imágenes RGB. La jerarquía de capas permite la extracción progresiva de características, desde detectores de bordes y texturas en capas tempranas hasta representaciones semánticas complejas en capas profundas.

El desarrollo de arquitecturas especializadas para detección de objetos y segmentación semántica ha facilitado la implementación de sistemas automatizados de análisis agrícola. Arquitecturas como YOLO (You Only Look Once), R-CNN y sus variantes han demostrado eficacia en la detección y localización automática de productos agrícolas en imágenes RGB. Para tareas de segmentación semántica, arquitecturas como U-Net, SegNet y DeepLab han mostrado resultados prometedores en la delimitación precisa de regiones de interés en imágenes agrícolas. Estas capacidades son fundamentales para el análisis posterior de características específicas de productos individuales.

La integración de información RGB e hiperespectral representa una frontera emergente en el análisis agrícola automatizado [3]. Los enfoques híbridos pueden aprovechar las ventajas complementarias de ambas modalidades: la simplicidad y velocidad del RGB para detección y localización, y la riqueza espectral de HSI para análisis químico detallado. Estos sistemas multimodales típicamente implementan arquitecturas de procesamiento en cascada, donde la información RGB se utiliza para la detección inicial y segmentación de productos, seguida por análisis hiperespectral detallado de las regiones de interés identificadas. Esta estrategia puede optimizar tanto la eficiencia computacional como la precisión de detección.

Las técnicas de fusión de características permiten la combinación sis-

temática de información extraída de diferentes modalidades de imagen. Estos enfoques pueden implementarse a diferentes niveles del pipeline de procesamiento: fusión temprana (combinación de datos raw), fusión intermedia (combinación de características extraídas) o fusión tardía (combinación de decisiones de clasificadores independientes). La fusión efectiva de características RGB e hiperespectrales requiere consideración cuidadosa de las diferencias en resolución espacial, rango dinámico y características estadísticas entre las modalidades. Técnicas de normalización y alineamiento espacial son críticas para el éxito de estos enfoques.

El análisis de la literatura revela fortalezas y limitaciones distintas en los enfoques actuales para la detección de contaminantes agrícolas. Los sistemas basados en HSI ofrecen capacidades superiores de detección química pero requieren recursos computacionales significativos y equipos especializados costosos [2]. Los sistemas RGB proporcionan soluciones más accesibles y eficientes pero con capacidades limitadas de detección temprana.

Las arquitecturas de deep learning han demostrado capacidades excepcionales en ambas modalidades, pero su implementación efectiva requiere datasets grandes y representativos que pueden ser costosos y tiempo-intensivos de generar. La transferibilidad de modelos entre diferentes cultivos, condiciones ambientales y sistemas de adquisición permanece como un desafío significativo.

Las oportunidades de innovación identificadas incluyen el desarrollo de arquitecturas híbridas que combinen eficientemente información RGB e hiperespectral, la implementación de técnicas de selección inteligente de características espectrales y el desarrollo de sistemas adaptativos que puedan operar efectivamente en condiciones variables de campo [10]. La integración de técnicas de optimización evolutiva, como algoritmos genéticos, para la selección automática de características espectrales representa una dirección prometedora para mejorar tanto la eficiencia como la precisión de los sistemas de detección. Estos enfoques pueden automatizar el proceso de identificación de bandas espectrales óptimas para aplicaciones específicas.

Capítulo 3

Desarrollo

3.1. Introducción

El desarrollo del proyecto se ha estructurado en múltiples fases secuenciales, cada una diseñada para abordar aspectos específicos del proceso de análisis hiperespectral aplicado a la detección de aflatoxinas en higos frescos. La metodología desarrollada implementa técnicas de visión por computador de última generación combinadas con procesamiento especializado de datos hiperespectrales para crear un sistema automatizado de análisis de muestras.

3.2. Entorno de Desarrollo

El proyecto se ha implementado utilizando un entorno de desarrollo adaptado para procesamiento de imágenes hiperespectrales y ejecución de modelos de aprendizaje profundo. A continuación se detallan los aspectos fundamentales de la infraestructura técnica utilizada.

3.2.1. Gestión de Entornos y Dependencias

El proyecto se desarrolló utilizando el lenguaje de programación *Python* [11] en su versión 3.13 con soporte para *Cython* [12], lo que proporcionó ventajas significativas en términos de rendimiento.

Para la gestión de entornos virtuales se utilizó *Conda* [13], un sistema que permite crear espacios de trabajo aislados con versiones específicas de bibliotecas.

Sobre la base de *Conda*, se implementó *UV* [14], un gestor de paquetes

y proyectos para *Python*, extremadamente rápido y escrito en *Rust* [15]. *UV* fue utilizado para la instalación y gestión de paquetes dentro del entorno *Conda*, aprovechando su capacidad para resolver dependencias de manera más eficiente y rápida que las herramientas tradicionales como *pip* o el propio instalador de *Conda*. Esta combinación permitió mantener un entorno consistente y reproducible mientras se optimizaba el tiempo de instalación y actualización de dependencias.

Para cada fase del proyecto se creó un paquete independiente con dependencias específicas según los requisitos de cada etapa. Las principales bibliotecas utilizadas en el proyecto incluyen:

- **PyTorch con torchvision y torchaudio:** Framework principal para implementación de modelos de aprendizaje profundo [16].
- **NumPy y SciPy:** Para operaciones numéricas y manipulación eficiente de matrices [17, 18].
- **Scikit-learn:** Para implementación de algoritmos de aprendizaje automático y métricas [19].
- **Spectral:** Biblioteca especializada para procesamiento de imágenes hiperespectrales [20].
- **OpenCV-Python:** Para operaciones de procesamiento de imágenes y visión por computador [21].
- **Transformers:** Para implementación y uso de modelos basados en arquitecturas de *transformers* [22].
- **Timm:** Colección de modelos preentrenados para tareas de visión por computador [23].
- **Supervision:** Para visualización y análisis de resultados de detección y segmentación [24].
- **PyCocoTools:** Para manipulación de anotaciones en formato *COCO* [25, 26, 27].
- **DEAP:** Para implementación de algoritmos genéticos y evolutivos [28].

Adicionalmente, se incorporaron bibliotecas auxiliares como **addict**, **colorlog**, **gdown**, **split-folders**, **submitit** y **termcolor** para tareas de

gestión de configuración, logging, descarga de modelos pre-entrenados, organización de datos y paralelización de tareas.

La gestión precisa de versiones de estas dependencias resultó crítica para garantizar la compatibilidad entre componentes y estabilidad del entorno de desarrollo.

3.2.2. Entorno de Desarrollo Integrado

Para el desarrollo del código se empleó Visual Studio Code (VS Code) como entorno de desarrollo integrado.

3.2.3. Infraestructura Computacional

El desarrollo y ejecución del proyecto se realizó en un servidor de alto rendimiento proporcionado por la Universidad de Extremadura, con las siguientes especificaciones técnicas:

- **Procesador:** Intel Xeon de última generación (detalles específicos a completar).
- **Memoria RAM:** 504 GB para procesamiento de grandes volúmenes de datos hiperespectrales.
- **Aceleradores GPU:** $4 \times$ NVIDIA A100 con 40 GB de memoria VRAM cada una, de las cuales se utilizó una para la ejecución de los modelos de aprendizaje profundo.
- **Almacenamiento:** Sistema de almacenamiento de alta velocidad para manejo eficiente del conjunto de datos hiperespectral (aproximadamente X TB).

3.2.4. Adquisición de Imágenes Hiperespectrales

Las imágenes fueron capturadas utilizando una cámara hiperespectral SPECIM, específicamente el modelo FX10 VNIR, cuyas características técnicas principales incluyen: resolución espacial de 1024 píxeles ($800 \text{ width} \times 1024 \text{ height}$), rango espectral de 400 nm a 1000 nm (visible y parte del infrarrojo cercano), 448 bandas espectrales, y un salto espectral de 1.339 nm.

El conjunto de datos comprende 320 higos cosechados de la plantación de la variedad calabacita ubicada en la “Finca La Orden-Valdesequera” ($38^{\circ}51'$

N, 6°40' W, altitud 184 m) en Guadajira, España, donde CICYTEX tiene su sede central. Las imágenes hiperespectrales se capturaron durante un período de 2 semanas, utilizando cada semana 160 higos cosechados en diferentes etapas de madurez.

Cada semana, 160 higos se dividieron en cuatro subconjuntos de aproximadamente 40 especímenes cada uno. El primer grupo correspondió a los controles sanos (clase 0), mientras que los tres grupos siguientes fueron inoculados con concentraciones de 10^3 UFC/mL (clase 1), 10^5 UFC/mL (clase 2), y 10^7 UFC/mL (clase 3), respectivamente. El proceso de inoculación se realizó mediante inmersión del área durante aproximadamente 3 segundos, siguiendo el protocolo establecido por CICYTEX.

Las imágenes hiperespectrales se capturaron *post*-inoculación cada 24 horas durante cinco días consecutivos. Entre cada sesión de adquisición, las muestras se almacenaron en una cámara de incubación controlada a 25°C, con humedad relativa entre 80 y 90 % para promover el crecimiento fúngico. Cada clase consistió de 380 imágenes hiperespectrales, generando un total de 1520 imágenes hiperespectrales para el conjunto de datos completo.

Las imágenes hiperespectrales capturadas se almacenan en una estructura de directorios organizada que incluye múltiples archivos asociados a cada adquisición. A continuación, se describe el formato y contenido de los archivos principales:

- **Archivos de datos hiperespectrales (.hdr, .raw):**
 - El archivo **.hdr** contiene metadatos descriptivos de la imagen, como dimensiones espaciales, número de bandas espectrales, rango espectral, y formato de datos.
 - El archivo **.raw** almacena los datos espectrales en bruto, organizados en un formato binario que representa la intensidad de cada banda para cada píxel.
- **Referencias de calibración (DARKREF, WHITEREF):**
 - Los archivos **DARKREF** y **WHITEREF** contienen las referencias oscura y blanca necesarias para la posterior corrección radiométrica de las imágenes hiperespectrales.
- **Imagen .png:**

- Este archivo representa una visualización en falso color RGB generada a partir de tres bandas seleccionadas del cubo hiperspectral. Se utiliza como entrada para el flujo de trabajo de detección y segmentación.
- **Archivos de metadatos (.xml):**
 - Contienen información adicional sobre las condiciones de captura, como fecha, hora, y parámetros experimentales.

Esta estructura permite un manejo eficiente de los datos, facilitando tanto la corrección radiométrica como la integración con el flujo de procesamiento automatizado.

3.3. Localización y Segmentación de Figuras

3.3.1. Objetivo de la Fase

La primera fase del proyecto consiste en la creación del conjunto de datos mediante la localización y segmentación automatizada de higos individuales sobre las imágenes creadas a través del falso color *RGB*. El objetivo principal es generar anotaciones precisas en formato COCO [29], que incluyan cuadros delimitadores y máscaras de segmentación para cada higo detectado, y extraer los subcubos hiperspectrales radiométricamente corregidos correspondientes a cada fruto.

Esta fase es fundamental para el flujo de trabajo completo, ya que permite el aislamiento automatizado de las regiones de interés que servirán como imágenes de entrada para el entrenamiento y la inferencia de la *CNN*. La precisión en esta etapa condiciona directamente la calidad de los datos que utilizará la red en las fases posteriores, por lo que resulta esencial garantizar su exactitud.

3.3.2. Herramientas y Tecnologías Empleadas

La implementación de esta fase se basa en la integración de modelos de visión por computador de última generación, complementados con librerías especializadas para el procesamiento de datos hiperspectrales y manipulación de anotaciones.

Grounding DINO

Grounding DINO [30, 31] es un modelo de inteligencia artificial de última generación especializado en la detección de objetos en imágenes mediante el uso combinado de descripciones textuales e información visual, permitiendo un análisis multimodal avanzado. Gracias a su arquitectura basada en *transformers* [32] y técnicas de aprendizaje profundo, puede localizar y etiquetar objetos de interés, sin necesidad de entrenamiento específico para cada tipo de objeto, lo que lo hace altamente adaptable para tareas de detección abiertas o *zero-shot* [33].

SAM2 (Segment Anything Model 2)

SAM (*Segment Anything Model*) [34, 35] es un modelo de inteligencia artificial de última generación diseñado para segmentar cualquier objeto en imágenes o videos de manera automática y versátil. Fue desarrollado por *Meta AI* y su objetivo principal es permitir la segmentación de objetos de imágenes y videos sin necesidad de entrenamiento específico para cada clase, usando tecnologías de visión por computador avanzadas y aprendizaje *zero-shot*. Está entrenado en uno de los mayores conjuntos de datos existentes (SA-1B), con 11 millones de imágenes y 1.1 mil millones de máscaras de segmentación, lo que le da una capacidad sobresaliente para generalizar a nuevos contextos visuales.

COCO (Common Objects in Context)

El formato COCO (Common Objects in Context) [29] es un estándar ampliamente adoptado para el almacenamiento y intercambio de anotaciones en tareas de visión por computador, especialmente en detección de objetos, segmentación de instancias y estimación de poses. Desarrollado por *Microsoft Research*, *COCO* define una estructura *JSON* [36] que organiza metadatos de imágenes, anotaciones de objetos y categorías de manera eficiente y escalable.

Entre las componentes que definen la estructura del formato *COCO*, se encuentran las **anotaciones** (*annotations*), las cuales contienen las anotaciones específicas de cada objeto detectado, incluyendo identificadores únicos, referencias a imagen y categoría, coordenadas de bounding box, área, máscaras de segmentación en formato *RLE* (*Run-Length Encoding*), y banderas adicionales como *iscrowd*, que indica si el objeto es parte de un grupo denso.

Para tareas de segmentación de instancias, las máscaras se codifican mediante *RLE*, un algoritmo de compresión sin pérdidas que representa secuen-

cias de píxeles consecutivos como pares (valor, longitud), reduciendo significativamente el espacio de almacenamiento requerido. Las coordenadas de bounding box se especifican en formato `[x, y, width, height]`, donde (x, y) representa la esquina superior izquierda del rectángulo delimitador.

3.3.3. Flujo de Procesamiento

La implementación del flujo de trabajo se diseñó siguiendo una arquitectura modular que separa conceptualmente la detección y anotación automatizada de la extracción de subcubos hiperespectrales. Esta separación se materializa en dos módulos principales: el primero responsable de la localización y segmentación de higos individuales sobre las imágenes RGB derivadas, y el segundo encargado de la extracción de los subcubos hiperespectrales correspondientes a cada detección validada.

El sistema adopta un patrón de procesamiento por lotes que opera sistemáticamente sobre la estructura jerárquica del conjunto de datos. Cada directorio de clase (C0, C1, C2, C3) contiene las imágenes hiperespectrales junto con sus archivos de metadatos y referencias de calibración.

1. Detección

El módulo de detección y segmentación constituye el núcleo del flujo automatizado. La implementación utiliza *Grounding DINO* como modelo de detección, empleando la arquitectura con la red principal (*backbone*) *Swin Transformer Base* y el punto de control preentrenado correspondiente. Esta configuración permite al modelo procesar imágenes *RGB* manteniendo su relación de aspecto original mientras utiliza la entrada de texto *fig* (higo en inglés) como descriptor semántico para guiar la detección.

La optimización de los parámetros de inferencia se estableció mediante experimentación empírica, fijando tanto el umbral de confianza de detección como el umbral de similaridad semántica texto-imagen en 0.25. Esta configuración proporciona un equilibrio óptimo entre sensibilidad de detección y precisión para el conjunto de datos específico, minimizando tanto los falsos positivos como los falsos negativos. El proceso de detección implementa una secuencia de validación que comienza con la carga de imágenes seguida de la conversión del espacio de color *BGR* a *RGB* y la extracción automática de metadatos temporales y experimentales del nombre del archivo.

Durante la inferencia, el modelo transforma las imágenes a tensores *Py-*

Torch aplicando la normalización correspondiente a los parámetros del modelo preentrenado, ejecuta la detección con la entrada de texto especificada y aplica un filtrado geométrico crítico que limita las dimensiones máximas de los cuadros delimitadores a 250×150 píxeles. Esta restricción dimensional resulta fundamental para asegurar la detección de higos individuales y evitar regiones que abarquen múltiples especímenes, un problema recurrente en imágenes con alta densidad de objetos. El post-procesamiento convierte las coordenadas al formato requerido por *SAM-2* y extrae las puntuaciones de confianza asociadas a cada detección.

2. Segmentación

La segmentación se realiza mediante *SAM-2*, inicializado con la configuración *Hiera Large* y el punto de control preentrenado correspondiente, utilizando el predictor específicamente diseñado para el procesamiento de imágenes estáticas. El modelo opera sin supervisión de puntos, empleando exclusivamente los cuadros delimitadores generados por *Grounding DINO* como entrada primaria. La configuración para una única máscara por detección asegura la generación coherente, simplificando el procesamiento posterior y manteniendo la consistencia en las anotaciones. La figura 3.1 muestra un ejemplo representativo del proceso de detección y segmentación automatizada implementado.

3. Generación de Anotaciones

La generación de anotaciones en formato *COCO* se realizó mediante la construcción sistemática de estructuras de datos que incluyen metadatos de imagen, información de categorías y listas de anotaciones. Cada máscara binaria generada por *SAM-2* se transforma al formato *RLE* mediante las herramientas correspondientes, calculando automáticamente el área de cada instancia y asignando identificadores únicos secuenciales. El sistema exporta los resultados como archivos *JSON* organizados por clase experimental, manteniendo la trazabilidad completa desde las imágenes originales hasta las anotaciones finales.

4. Extracción de Subcubos Hiperespectrales

El último componente del flujo se encarga de la extracción de sub-cubos hiperespectrales radiométricamente corregidos a partir de las detecciones validadas en la fase anterior. Este módulo implementa un procesamiento sofisticado que combina corrección radiométrica, mapeo geométrico y extracción




Figura 3.1: Ejemplo de detección y segmentación de higos utilizando *Grounding DINO* y *SAM-2*. La imagen muestra las cajas delimitadoras generadas por *Grounding DINO* y las máscaras de segmentación producidas por *SAM-2*.

volumétrica para generar datos hiperspectrales de alta calidad correspondientes a cada higo individual detectado.

La corrección radiométrica constituye un paso crítico para garantizar la calidad de los datos hiperspectrales, eliminando efectos de iluminación y variaciones instrumentales que podrían comprometer el análisis posterior. El proceso utiliza las referencias oscura y blanca capturadas simultáneamente con cada imagen hiperspectral, aplicando la ecuación estándar de corrección:

$$R = \frac{RAW - DARK}{WHITE - DARK} \quad (3.1)$$

donde R representa la reflectancia corregida, RAW los datos espectrales en bruto, $DARK$ la referencia oscura y $WHITE$ la referencia blanca. La implementación incluye el tratamiento robusto de casos especiales, como la prevención de divisiones por cero en regiones donde las referencias oscura y blanca presentan valores idénticos, situación que puede ocurrir en áreas de

muy baja reflectancia.

La extracción geométrica de sub-cubos requiere una transformación precisa desde el espacio de coordenadas *RGB*, donde se realizaron las detecciones, al espacio hiperespectral correspondiente. Esta conversión considera las posibles diferencias en resolución espacial entre las imágenes *RGB* derivadas y los cubos hiperespectrales originales, implementando técnicas de mapeo que preservan la correspondencia espacial exacta. El sistema valida geométricamente cada región de interés para asegurar que los subcubos extraídos no excedan los límites físicos del cubo hiperespectral, evitando errores de indexación y garantizando la integridad de los datos espectrales.

El proceso de extracción volumétrica utiliza técnicas de división tridimensional optimizadas para mantener la estructura espectral completa de cada región de interés. Los subcubos resultantes preservan las 448 bandas espectrales originales junto con la resolución espacial correspondiente a cada detección, manteniendo la información espectral íntegra necesaria para el análisis posterior. La organización del almacenamiento sigue una estructura jerárquica específica, con subdirectorios organizados por clase experimental (*C0*, *C1*, *C2*, *C3*). Cada subcubo se almacena en formato *.npy* de *NumPy* siguiendo una nomenclatura sistemática que incluye clase, timestamp y número de instancia, facilitando tanto el acceso eficiente como la trazabilidad completa mientras preserva la precisión numérica de punto flotante y optimiza los tiempos de carga durante el entrenamiento de modelos.

3.3.4. Resultados

La ejecución completa de la primera fase genera un conjunto estructurado de elementos que constituyen la base fundamental para las fases posteriores del proyecto. Las anotaciones *COCO* resultantes comprenden archivos *JSON* organizados por clase experimental, cada uno conteniendo metadatos completos de detección que incluyen coordenadas de cuadros delimitadores, máscaras de segmentación en formato *RLE* y metadatos temporales extraídos automáticamente del sistema de nomenclatura implementado. Esta organización sistemática permite mantener la trazabilidad completa desde las imágenes originales hasta las detecciones finales, facilitando tanto la validación manual como el procesamiento automatizado en etapas subsecuentes.


```

{
  "info": {
    "description": "Fig detection and segmentation dataset",
    "version": "1.0",
    "year": 2024,
    "contributor": "Hyperspectral Analysis Pipeline",
    "date_created": "2024-01-15"
  },
  "licenses": [],
  "images": [
    {
      "id": 1,
      "width": 800,
      "height": 1024,
      "file_name": "C0_2023-07-17_10-15-30_001.png",
      "date_captured": "2023-07-17T10:15:30"
    }
  ],
  "annotations": [
    {
      "id": 1,
      "image_id": 1,
      "category_id": 1,
      "segmentation": {
        "size": [1024, 800],
        "counts": "nXh04M3M2N2N10101N2N2N10101N2N..."
      },
      "area": 12485,
      "bbox": [245.3, 412.7, 128.4, 97.2],
      "iscrowd": 0
    }
  ],
  "categories": [
    {
      "id": 1,
      "name": "fig",
      "supercategory": "fruit"
    }
  ]
}

```

Figura 3.2: Ejemplo de anotación en formato COCO para la clase 0.

3.3.5. Desafíos y Observaciones Técnicas

Durante la implementación, se identificaron y resolvieron varios desafíos técnicos que proporcionaron valiosas lecciones para el desarrollo del proyecto. El primer y más significativo desafío encontrado fue determinar las versiones correctas de *PyTorch* y sus dependencias relacionadas (*torchvision* y *torchaudio*) que fueran compatibles tanto con *Grounding DINO* como con *SAM-2*. Ambos modelos requieren versiones específicas del framework que no siempre coinciden, especialmente considerando las actualizaciones frecuentes en el ecosistema de aprendizaje profundo. La solución final involucró el análisis detallado de los requisitos de compatibilidad de cada modelo y la identificación de una versión común de *PyTorch* 2.1.2 con soporte *CUDA* 11.8 que proporcionara estabilidad y rendimiento óptimo para ambos componentes.

La optimización de la memoria de la *GPU* constituyó otro reto importante, dado que el procesamiento conjunto de *Grounding DINO* y *SAM-2* requirió una implementación cuidadosa de contextos autocast para prevenir desbordamientos de memoria. La solución implementada aplica precisión mixta de forma selectiva [37]: utiliza `torch.autocast` con `dtype=torch.bfloat16` únicamente para *SAM-2*, mientras mantiene precisión completa para *Grounding DINO*, equilibrando eficiencia computacional con calidad de inferencia. La elección del formato `bfloat16` se fundamenta en su diseño específico para aplicaciones de aprendizaje profundo, proporcionando un rango dinámico superior a `float16` tradicional [38]. Adicionalmente, se configuró el uso de *TF32* cuando está disponible en hardware compatible para optimizar las operaciones de multiplicación de matrices.

3.4. Selección de Bandas con Algoritmo Genético

3.4.1. [Sección reservada para Fase 2: Selección de Bandas con Algoritmo Genético]

Capítulo 4

Resultados

Capítulo 5

Conclusiones y Trabajo Futuro

5.1. Conclusiones

5.1.1. Logros Principales

Capítulo 6

Agradecimientos

Bibliografía

- [1] I. Cisternas, I. Velásquez, A. Caro, and A. Rodríguez, “Systematic literature review of implementations of precision agriculture,” *Computers and Electronics in Agriculture*, vol. 176, p. 105626, 2020.
- [2] A. Khan, A. D. Vibhute, S. Mali, and C. Patil, “A systematic review on hyperspectral imaging technology with a machine and deep learning methodology for agricultural applications,” *Ecological Informatics*, vol. 69, p. 101678, 2022.
- [3] A. Signoroni, M. Savardi, A. Baronio, and S. Benini, “Deep learning meets hyperspectral image analysis: A multidisciplinary review,” *Journal of Imaging*, vol. 5, no. 5, 2019.
- [4] C. Cruz-Carrasco, J. Díaz-Álvarez, F. Chávez de la O, A. Sánchez-Venegas, and J. Villegas Cortez, “Detection of aspergillus flavus in figs by means of hyperspectral images and deep learning algorithms,” *AgriEngineering*, vol. 6, no. 4, pp. 3969–3988, 2024.
- [5] D. Hong, N. Yokoya, J. Chanussot, J. Xu, and X. X. Zhu, “Learning to propagate labels on graphs: An iterative multitask regression framework for semi-supervised hyperspectral dimensionality reduction,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, pp. 35–49, 2019.
- [6] K. P. Ferentinos, “Deep learning models for plant disease detection and diagnosis,” *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018.
- [7] M. Paoletti, J. Haut, J. Plaza, and A. Plaza, “Deep learning classifiers for hyperspectral imaging: A review,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, pp. 279–317, 2019.
- [8] Y. Chen, Z. Lin, X. Zhao, G. Wang, and Y. Gu, “Deep learning-based classification of hyperspectral data,” *Selected Topics in Applied Earth*

- Observations and Remote Sensing, IEEE Journal of*, vol. 7, pp. 2094–2107, 06 2014.
- [9] Z. Zhong, J. Li, Z. Luo, and M. Chapman, “Spectral-spatial residual network for hyperspectral image classification: A 3-d deep learning framework,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, pp. 847–858, 10 2017.
 - [10] J. Wieme, K. Mollazade, I. Malounas, M. Zude-Sasse, M. Zhao, A. Gowen, D. Argyropoulos, S. Fountas, and J. Van Beek, “Application of hyperspectral imaging systems and artificial intelligence for quality assessment of fruit, vegetables and mushrooms: A review,” *Biosystems Engineering*, vol. 222, pp. 156–176, 2022.
 - [11] G. Van Rossum and F. L. Drake Jr, *Python tutorial*. Centrum voor Wiskunde en Informatica Amsterdam, The Netherlands, 1995.
 - [12] S. Behnel, R. Bradshaw, C. Citro, L. Dalcin, D. S. Seljebotn, and K. Smith, “Cython: The best of both worlds,” *Computing in Science & Engineering*, vol. 13, no. 2, pp. 31–39, 2011.
 - [13] “Anaconda software distribution,” 2020.
 - [14] Astral, “Uv: An extremely fast python package installer and resolver,” 2024. GitHub Repository. Disponible en: <https://github.com/astral-sh/uv>.
 - [15] N. D. Matsakis and F. S. Klock II, “The rust language,” in *ACM SIGAda Ada Letters*, vol. 34, pp. 103–104, ACM, 2014.
 - [16] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “Pytorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems 32*, pp. 8024–8035, Curran Associates, Inc., 2019.
 - [17] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. Fernández del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, “Array programming with NumPy,” *Nature*, vol. 585, p. 357–362, 2020.

- [18] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, S. J. van der Walt, M. Brett, J. Wilson, K. J. Millman, N. Mayorov, A. R. J. Nelson, E. Jones, R. Kern, E. Larson, C. J. Carey, Í. Polat, Y. Feng, E. W. Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, E. A. Quintero, C. R. Harris, A. M. Archibald, A. H. Ribeiro, F. Pedregosa, P. van Mulbregt, and SciPy 1.0 Contributors, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [19] L. Buitinck, G. Louppe, M. Blondel, F. Pedregosa, A. Mueller, O. Grisel, V. Niculae, P. Prettenhofer, A. Gramfort, J. Grobler, R. Layton, J. VanderPlas, A. Joly, B. Holt, and G. Varoquaux, “API design for machine learning software: experiences from the scikit-learn project,” in *ECML PKDD Workshop: Languages for Data Mining and Machine Learning*, pp. 108–122, 2013.
- [20] T. Boggs, D. March, kormang, L. J. McGibbney, F. Magimel, G. Mason, K. Banman, M. J. L. Uzumaki), R. Kumar, T. G. Badger, T. Aarnio, W. Wang, and kidpixo, “spectralpython/spectral: Spectral python (spy) 0.23.1,” Oct. 2022.
- [21] G. Bradski, “The OpenCV Library,” *Dr. Dobb’s Journal of Software Tools*, 2000.
- [22] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, P. von Platen, C. Ma, Y. Jernite, J. Plu, C. Xu, T. L. Scao, S. Gugger, M. Drame, Q. Lhoest, and A. M. Rush, “Transformers: State-of-the-art natural language processing,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, (Online), pp. 38–45, Association for Computational Linguistics, Oct. 2020.
- [23] R. Wightman, “Pytorch image models.” <https://github.com/rwightman/pytorch-image-models>, 2019.
- [24] Roboflow, “Supervision.”
- [25] C. M. Welsh, N. Fullard, C. J. Proctor, A. Martinez-Guimera, R. J. Isfort, C. C. Bascom, R. Tasseff, S. A. Przyborski, and D. P. Shanley, “Pycotools: a python toolbox for copasi,” *Bioinformatics*, vol. 34, no. 21, pp. 3702–3710, 2018.

- [26] S. Hoops, S. Sahle, R. Gauges, C. Lee, J. Pahle, N. Simus, M. Singhal, L. Xu, P. Mendes, and U. Kummer, “Copasi—a complex pathway simulator,” *Bioinformatics*, vol. 22, no. 24, pp. 3067–3074, 2006.
- [27] J. K. Medley, K. Choi, M. König, L. Smith, S. Gu, J. Hellerstein, S. C. Sealfon, and H. M. Sauro, “Tellurium notebooks—an environment for reproducible dynamical modeling in systems biology,” *PLOS Computational Biology*, vol. 14, no. 6, p. e1006220, 2018.
- [28] F.-A. Fortin, F.-M. De Rainville, M.-A. Gardner, M. Parizeau, and C. Gagné, “DEAP: Evolutionary algorithms made easy,” *Journal of Machine Learning Research*, vol. 13, pp. 2171–2175, jul 2012.
- [29] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, “Microsoft coco: Common objects in context,” 2015.
- [30] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu, *et al.*, “Grounding dino: Marrying dino with grounded pre-training for open-set object detection,” *arXiv preprint arXiv:2303.05499*, 2023.
- [31] T. Ren, Q. Jiang, S. Liu, Z. Zeng, W. Liu, H. Gao, H. Huang, Z. Ma, X. Jiang, Y. Chen, Y. Xiong, H. Zhang, F. Li, P. Tang, K. Yu, and L. Zhang, “Grounding dino 1.5: Advance the .edge.of open-set object detection,” 2024.
- [32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023.
- [33] R. Socher, M. Ganjoo, H. Sridhar, O. Bastani, C. D. Manning, and A. Y. Ng, “Zero-shot learning through cross-modal transfer,” 2013.
- [34] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, “Segment anything,” *arXiv:2304.02643*, 2023.
- [35] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rädle, C. Rolland, L. Gustafson, E. Mintun, J. Pan, K. V. Alwala, N. Carion, C.-Y. Wu, R. Girshick, P. Dollár, and C. Feichtenhofer, “Sam 2: Segment anything in images and videos,” 2024.
- [36] D. Crockford, “The application/json media type for javascript object notation (json),” Tech. Rep. RFC 4627, Internet Engineering Task Force (IETF), 2006.

- [37] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh, and H. Wu, “Mixed precision training,” 2018.
- [38] A. Agrawal, S. M. Mueller, B. M. Fleischer, X. Sun, N. Wang, J. Choi, and K. Gopalakrishnan, “Dlfloat: A 16-b floating point format designed for deep learning training and inference,” in *2019 IEEE 26th Symposium on Computer Arithmetic (ARITH)*, pp. 92–95, 2019.
- [39] R. Sahoo, S. Ray, and M. R, “Hyperspectral remote sensing of agriculture,” *Current science*, vol. 108, pp. 848–859, 03 2015.
- [40] T. Ren, S. Liu, A. Zeng, J. Lin, K. Li, H. Cao, J. Chen, X. Huang, Y. Chen, F. Yan, Z. Zeng, H. Zhang, F. Li, J. Yang, H. Li, Q. Jiang, and L. Zhang, “Grounded sam: Assembling open-world models for diverse visual tasks,” 2024.
- [41] Q. Jiang, F. Li, Z. Zeng, T. Ren, S. Liu, and L. Zhang, “T-rex2: Towards generic object detection via text-visual prompt synergy,” 2024.